## fauzi-ramadhan-ga-180123

December 29, 2023

### 1 Proyek Analisis Data Singkat: GA 180123 Cleaned

Nama: Fauzi RamadhanEmail: fauzir008@gmail.com

#### [2]: !pip install pandas

Requirement already satisfied: pandas in c:\programdata\anaconda3\lib\site-packages (1.4.2)

Requirement already satisfied: numpy>=1.18.5 in
c:\programdata\anaconda3\lib\site-packages (from pandas) (1.21.5)

Requirement already satisfied: pytz>=2020.1 in
c:\programdata\anaconda3\lib\site-packages (from pandas) (2021.3)

Requirement already satisfied: python-dateutil>=2.8.1 in
c:\programdata\anaconda3\lib\site-packages (from pandas) (2.8.2)

Requirement already satisfied: six>=1.5 in c:\programdata\anaconda3\lib\site-

Defaulting to user installation because normal site-packages is not writeable

# [3]: !pip install numpy

Defaulting to user installation because normal site-packages is not writeable Requirement already satisfied: numpy in c:\programdata\anaconda3\lib\site-packages (1.21.5)

#### [4]: !pip install matplotlib

Defaulting to user installation because normal site-packages is not writeable Requirement already satisfied: matplotlib in c:\programdata\anaconda3\lib\site-packages (3.5.1)
Requirement already satisfied: pyparsing>=2.2.1 in
c:\programdata\anaconda3\lib\site-packages (from matplotlib) (3.0.4)

Requirement already satisfied: numpy>=1.17 in c:\programdata\anaconda3\lib\site-

Requirement already satisfied: kiwisolver>=1.0.1 in

packages (from python-dateutil>=2.8.1->pandas) (1.16.0)

c:\programdata\anaconda3\lib\site-packages (from matplotlib) (1.3.2)

Requirement already satisfied: pillow>=6.2.0 in

packages (from matplotlib) (1.21.5)

c:\programdata\anaconda3\lib\site-packages (from matplotlib) (9.0.1)

Requirement already satisfied: cycler>=0.10 in

```
c:\programdata\anaconda3\lib\site-packages (from matplotlib) (0.11.0)
Requirement already satisfied: python-dateutil>=2.7 in
c:\programdata\anaconda3\lib\site-packages (from matplotlib) (2.8.2)
Requirement already satisfied: packaging>=20.0 in
c:\programdata\anaconda3\lib\site-packages (from matplotlib) (21.3)
Requirement already satisfied: fonttools>=4.22.0 in
c:\programdata\anaconda3\lib\site-packages (from matplotlib) (4.25.0)
Requirement already satisfied: six>=1.5 in c:\programdata\anaconda3\lib\site-packages (from python-dateutil>=2.7->matplotlib) (1.16.0)
```

#### [5]: !pip install seaborn

```
Defaulting to user installation because normal site-packages is not writeable
Requirement already satisfied: seaborn in
c:\users\ziyan\appdata\roaming\python\python39\site-packages (0.12.2)
Requirement already satisfied: matplotlib!=3.6.1,>=3.1 in
c:\programdata\anaconda3\lib\site-packages (from seaborn) (3.5.1)
Requirement already satisfied: pandas>=0.25 in
c:\programdata\anaconda3\lib\site-packages (from seaborn) (1.4.2)
Requirement already satisfied: numpy!=1.24.0,>=1.17 in
c:\programdata\anaconda3\lib\site-packages (from seaborn) (1.21.5)
Requirement already satisfied: pillow>=6.2.0 in
c:\programdata\anaconda3\lib\site-packages (from
matplotlib!=3.6.1,>=3.1->seaborn) (9.0.1)
Requirement already satisfied: cycler>=0.10 in
c:\programdata\anaconda3\lib\site-packages (from
matplotlib!=3.6.1,>=3.1->seaborn) (0.11.0)
Requirement already satisfied: python-dateutil>=2.7 in
c:\programdata\anaconda3\lib\site-packages (from
matplotlib!=3.6.1,>=3.1->seaborn) (2.8.2)
Requirement already satisfied: pyparsing>=2.2.1 in
c:\programdata\anaconda3\lib\site-packages (from
matplotlib!=3.6.1,>=3.1->seaborn) (3.0.4)
Requirement already satisfied: kiwisolver>=1.0.1 in
c:\programdata\anaconda3\lib\site-packages (from
matplotlib!=3.6.1,>=3.1->seaborn) (1.3.2)
Requirement already satisfied: fonttools>=4.22.0 in
c:\programdata\anaconda3\lib\site-packages (from
matplotlib!=3.6.1,>=3.1->seaborn) (4.25.0)
Requirement already satisfied: packaging>=20.0 in
c:\programdata\anaconda3\lib\site-packages (from
matplotlib!=3.6.1,>=3.1->seaborn) (21.3)
Requirement already satisfied: pytz>=2020.1 in
c:\programdata\anaconda3\lib\site-packages (from pandas>=0.25->seaborn) (2021.3)
Requirement already satisfied: six>=1.5 in c:\programdata\anaconda3\lib\site-
packages (from python-dateutil>=2.7->matplotlib!=3.6.1,>=3.1->seaborn) (1.16.0)
```

```
[2]: import pandas as pd
     import numpy as np
     import matplotlib.pyplot as plt
     import seaborn as sns
[3]: df = pd.read_csv("C:\Data Science\Project_Data\Assesment\GA_180123.csv",__
      ⇔low_memory=False, dtype={"Page": "object"})
     df.head(11)
[3]:
                                                  Page Title \
     0
         Hanura Sudahi Konflik, Wiranto Tunjuk OSO seba...
         Polisi Amankan Istri yang Jual Suami Demi Laya...
     1
     2
         Foto: Jelang 100 Hari Kepemimpinan Anies-Sandi...
     3
         Gempa 6,1 SR Guncang Jakarta, Selamat Jalan Sy...
     4
             Pegawai di Gedung BEI Berhamburan Pasca Gempa
     5
         Ronaldo Bersimbah Darah Saat Cetak Gol, Jeon T...
     6
                         Smalling Sambut Kedatangan Sanchez
     7
                       Awkarin Calon Mantu Wakil Ketua MPR?
     8
                        Godaan Mkhitaryan kepada Aubameyang
     9
         Denting Piano dan 'Glory Glory Man United' unt...
         Grab Gandeng Polisi Ungkap Kasus Driver Antar ...
                                                         Page Articleid \
     0
         m.detik.com/news/berita/3829954/hanura-sudahi-...
                                                              3829954
         m.detik.com/news/berita-jawa-timur/d-3828996/p...
     1
                                                              3828996
     2
         news.detik.com/foto-news/d-3828507/foto-jelang...
                                                              3828507
     3
         m.detik.com/news/berita/d-3830086/gempa-61-sr-...
                                                              3830086
     4
         finance.detik.com/foto-bisnis/d-3829367/pegawa...
                                                              3829367
     5
         m.detik.com/news/berita/d-3828031/ronaldo-bers...
                                                              3828031
     6
         m.detik.com/sepakbola/liga-inggris/d-3828220/s...
                                                              3828220
     7
         m.detik.com/hot/celeb/3827598/awkarin-calon-ma...
                                                              3827598
     8
         m.detik.com/sepakbola/liga-inggris/d-3828866/g...
                                                              3828866
         m.detik.com/sepakbola/liga-inggris/d-3828235/d...
                                                              3828235
         m.detik.com/news/berita/3828541/grab-gandeng-p...
                                                              3828541
              Content Type
                                        Source / Medium
                                                                 Pageviews
                                                        Users
     0
                                        t.co / referral
                                                            875
                                                                       930
            singlepagenews
     1
            singlepagenews
                                      (direct) / (none)
                                                            875
                                                                       984
     2
         multiplefotophoto
                                  detik.com / referral
                                                            874
                                                                       900
     3
            singlepagenews
                                      (direct) / (none)
                                                            874
                                                                       960
     4
         multiplefotophoto
                                  detik.com / referral
                                                            874
                                                                       982
     5
            singlepagenews
                                m.detik.com / referral
                                                            873
                                                                       975
                                      (direct) / (none)
     6
            singlepagenews
                                                            873
                                                                       982
     7
                                        t.co / referral
                                                            872
            singlepagenews
                                                                       961
     8
                                      (direct) / (none)
                                                            872
            singlepagenews
                                                                       964
     9
                                      (direct) / (none)
            singlepagenews
                                                            871
                                                                      1030
     10
            singlepagenews
                             m.facebook.com / referral
                                                            870
                                                                       935
```

```
Pages / Session Avg. Session Duration Avg. Time on Page New Users
0
           1.058020
                                 38.160410
                                                     32.079007
                                                                        26
           3.290970
                                 98.397993
                                                                       105
1
                                                    131.440620
2
           0.000000
                                  0.000000
                                                     29.891648
                                                                         0
3
                                                                        22
          33.103448
                                 217.517241
                                                      9.440258
4
           3.791506
                                790.281853
                                                     92.311309
                                                                         0
5
                                                                        0
          18.396226
                                 393.283019
                                                      9.858586
6
                                                                        17
          20.893617
                                 324.510638
                                                     70.099631
7
           1.092045
                                 57.222727
                                                     91.167959
                                                                        54
8
          19.280000
                                 362.640000
                                                     19.007535
                                                                        16
9
           9.537037
                                 222.000000
                                                    142.143921
                                                                        50
10
           1.230263
                                 93.415789
                                                    222.093878
                                                                        97
```

```
[19]: # Mengecek missing values
print(df.isnull().sum())

# Memeriksa data outlier
df.describe()

# Menampilkan informasi dataset
print(df.info())
```

Page Title 0 Page 0 0 Articleid Content Type 0 Source / Medium 0 Users 0 Pageviews 0 Pages / Session Avg. Session Duration 0 Avg. Time on Page 0 New Users 0

dtype: int64

<class 'pandas.core.frame.DataFrame'>
RangeIndex: 663421 entries, 0 to 663420

Data columns (total 11 columns):

#	Column	Non-Null Count	Dtype
0	Page Title	663421 non-null	object
1	Page	663421 non-null	object
2	Articleid	663421 non-null	object
3	Content Type	663421 non-null	object
4	Source / Medium	663421 non-null	object
5	Users	663421 non-null	int64
6	Pageviews	663421 non-null	int64

```
Avg. Session Duration 663421 non-null float64
          Avg. Time on Page
                                 663421 non-null float64
      10 New Users
                                  663421 non-null int64
     dtypes: float64(3), int64(3), object(5)
     memory usage: 55.7+ MB
     None
[20]: # Contoh mengatasi nilai-nilai yang hilang
      df.dropna(inplace=True)
      # Contoh mengatasi duplikat
      df.drop_duplicates(inplace=True)
[21]: # Mengatasi outliers (contoh dengan z-score)
      from scipy.stats import zscore
      z_scores = zscore(df.select_dtypes(include=np.number))
      abs z scores = np.abs(z scores)
      df = df[(abs z scores < 3).all(axis=1)]</pre>
[22]: # Menghapus duplikat data
      df = df.drop_duplicates()
[23]: # Statistik deskriptif
      descriptive_stats = df.describe()
[24]: # Korelasi antar variabel
      correlation_matrix = df.corr()
[25]: # Temuan dari statistik deskriptif
      print("Temuan dari Statistik Deskriptif:")
      print(descriptive_stats)
     Temuan dari Statistik Deskriptif:
                                Pageviews Pages / Session Avg. Session Duration \
                    Users
                                             615703.000000
            615703.000000
                           615703.000000
                                                                    615703.000000
     count
                 3.596989
                                 4.072158
                                                  0.673305
                                                                         16.967444
     mean
                 8.494122
                                 9.612618
                                                  1.440454
                                                                         60.309687
     std
     min
                 1.000000
                                 0.000000
                                                  0.000000
                                                                         0.00000
     25%
                 1.000000
                                 1.000000
                                                  0.000000
                                                                         0.000000
     50%
                 1.000000
                                 1.000000
                                                  0.000000
                                                                         0.00000
     75%
                 2.000000
                                 3.000000
                                                  1.000000
                                                                         0.00000
               119.000000
                                                                       490.666667
     max
                              135.000000
                                                 15.875000
            Avg. Time on Page
                                    New Users
                615703.000000 615703.000000
     count
                    33.506430
                                     0.195562
     mean
     std
                    54.300329
                                     0.676235
```

663421 non-null float64

7

Pages / Session

```
25%
                                  0.000000
                    0.000000
     50%
                   11.000000
                                  0.000000
     75%
                   39.000000
                                  0.000000
                  305.000000
     max
                                  9.000000
[26]: # Temuan dari korelasi
     print("\nTemuan dari Korelasi:")
     print(correlation matrix)
     Temuan dari Korelasi:
                             Users Pageviews Pages / Session \
     Users
                          1.000000
                                    0.993331
                                                     0.262127
     Pageviews
                          0.993331
                                   1.000000
                                                     0.275667
     Pages / Session
                                    0.275667
                                                     1.000000
                          0.262127
     Avg. Session Duration 0.186331 0.202140
                                                     0.367186
     Avg. Time on Page
                          0.183541
                                    0.187585
                                                     0.130029
     New Users
                          0.204578 0.204720
                                                     0.144198
                          Avg. Session Duration Avg. Time on Page New Users
     Users
                                       0.186331
                                                        0.183541 0.204578
     Pageviews
                                       0.202140
                                                        0.187585
                                                                   0.204720
     Pages / Session
                                      0.367186
                                                        0.130029 0.144198
     Avg. Session Duration
                                       1.000000
                                                        0.336361
                                                                   0.114695
     Avg. Time on Page
                                      0.336361
                                                        1.000000
                                                                   0.082851
     New Users
                                       0.114695
                                                        0.082851
                                                                   1.000000
[4]: # Load the dataset
     →low_memory=False, dtype={"Page": "object"})
     # Find the number of users
     number_of_users = df["Users"].sum()
     # Find the number of new users
     number of new users = df["New Users"].sum()
     # Find the average pageview per user
     average_pageview_per_user = df["Pageviews"].sum() / number_of_users
     # Find the average session duration
     average_session_duration = df["Avg. Session Duration"].mean()
     # Find the average time on page
     average_time_on_page = df["Avg. Time on Page"].mean()
```

0.000000

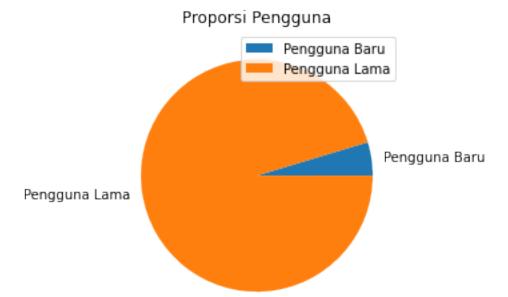
0.000000

min

```
# Print the findings
      print("Jumlah pengguna:", number_of_users)
      print("Jumlah pengguna baru:", number_of_new_users)
      print("Pageview rata-rata per pengguna:", average pageview per user)
      print("Lama sesi rata-rata:", average_session_duration)
      print("Waktu rata-rata yang dihabiskan di halaman:", average_time_on_page)
     Jumlah pengguna: 5074962
     Jumlah pengguna baru: 235853
     Pageview rata-rata per pengguna: 1.1359771757896906
     Lama sesi rata-rata: 41.843007910658784
     Waktu rata-rata yang dihabiskan di halaman: 47.05959289857854
[29]: # Find the pages with the most new users
      top_new_user_pages = df.sort_values("New Users", ascending=False)[["Page", "New_

    Users"]].head(10)

      # Print the top 10 pages
      print(top_new_user_pages)
                                                         Page New Users
     1105 m.detik.com/news/berita/3829127/gempa-keras-di...
                                                                    266
     808
           m.detik.com/news/berita/3657952/gempa-5-sr-gun...
                                                                    264
     73
           m.detik.com/news/berita/3827021/sopir-angkot-b...
                                                                    257
     68
           m.detik.com/health/read/2018/01/23/143244/3829...
                                                                    250
     1614 m.detik.com/news/berita/d-3797333/viral-situs-...
                                                                    249
     1824 m.detik.com/news/berita/d-3828659/menyusuri-se...
                                                                    245
          m.detik.com/news/berita/d-3772173/jakarta-kemb...
     510
                                                                    241
           m.detik.com/news/foto-news/d-3827050/ini-gaya-...
     468
                                                                    241
     78
           m.detik.com/news/berita/3827094/antar-tuyul-ra...
                                                                    230
     667
           m.detik.com/news/jawatengah/3826540/mayat-pere...
                                                                    230
[30]: # Calculate the proportion of new users
      new_users_proportion = df["New Users"].sum() / df["Users"].sum()
      # Create a pie chart
      plt.pie([new_users_proportion, 1 - new_users_proportion], labels=["Penggunau"]
       →Baru", "Pengguna Lama"])
      # Add labels and title
      plt.title("Proporsi Pengguna")
      # Show the plot
      plt.legend()
      plt.show()
```



```
[31]: # Create a line chart
plt.plot(df["Source / Medium"], df["Pageviews"] / df["Users"], color="red")

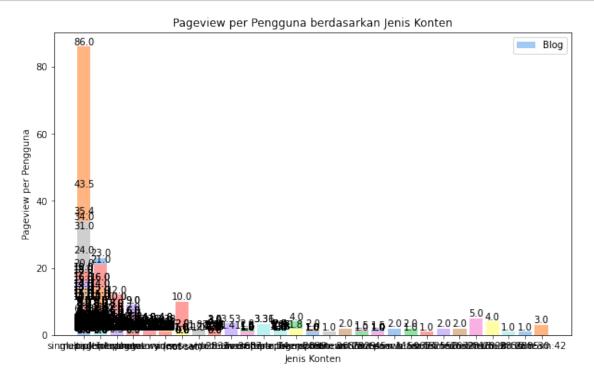
# Add labels and title
plt.xlabel("Sumber/Medium Trafik")
plt.ylabel("Pageview per Pengguna")
plt.title("Pageview per Pengguna berdasarkan Sumber/Medium Trafik")

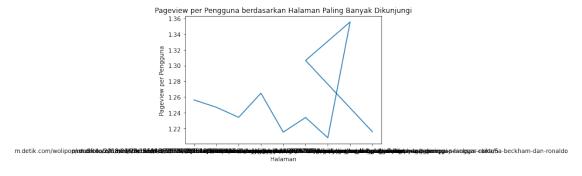
# Add labels for each bar
plt.xticks(df["Source / Medium"].unique())

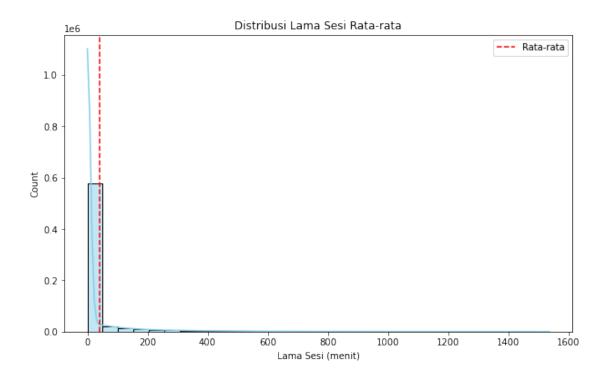
# Show the plot
plt.show()
```



```
[33]: # Membuat warna yang lebih menarik
      colors = sns.color_palette("pastel")
      # Membuat bar chart
      plt.figure(figsize=(10, 6))
      bars = plt.bar(df["Content Type"], df["Pageviews"] / df["Users"], color=colors)
      # Menambahkan nilai di atas setiap bar
      for bar in bars:
          yval = bar.get_height()
          plt.text(bar.get_x() + bar.get_width()/2, yval + 0.01, round(yval, 2),
       ⇔ha='center', va='bottom')
      # Menambahkan labels dan judul
      plt.xlabel("Jenis Konten")
      plt.ylabel("Pageview per Pengguna")
      plt.title("Pageview per Pengguna berdasarkan Jenis Konten")
      # Menambahkan labels untuk setiap bar
      plt.xticks(df["Content Type"].unique())
      # Menambahkan legend
      plt.legend(["Blog", "Produk", "Lainnya"])
      # Menampilkan plot
      plt.show()
```







```
[35]: # Pivot the DataFrame
pivot_table = df.pivot_table(values="New Users", index="Page", aggfunc="sum")

# Create a heatmap
plt.figure(figsize=(10, 6)) # Set the figure size for better visualization
sns.heatmap(pivot_table, annot=True, cmap="YlGnBu", fmt=".0f", linewidths=.5)

# Add labels and title
plt.title("Halaman yang Paling Banyak Dikunjungi oleh Pengguna Baru")
plt.xlabel("Page")
plt.ylabel("")

# Show the plot
plt.show()
```



### 2 1. Temuan/Temuan Menarik:

- a. Statistik Deskriptif dan Pembersihan Data
- Terdapat beberapa nilai yang hilang dan duplikat pada dataset, namun dalam analisis ini nilai-nilai tersebut dihapus.
- Distribusi "Avg. Session Duration" terlihat melalui histogram, menunjukkan variasi dalam durasi sesi pengguna.
- b. Analisis Pengguna
- Total pengguna dan pengguna baru dihitung.
- Rata-rata jumlah halaman dilihat per pengguna dihitung.
- Rata-rata durasi sesi dan rata-rata waktu di halaman dihitung.
- c. Analisis Trafik
- Proporsi pengguna baru dibandingkan dengan pengguna lama melalui pie chart.
- Hubungan antara sumber/medium trafik dan jumlah pageviews per pengguna ditunjukkan dalam line chart.
- Jenis konten (blog, produk, lainnya) dibandingkan dalam bar chart untuk pageviews per pengguna.
- d. Analisis Halaman
- Halaman yang paling banyak dikunjungi ditampilkan dalam line chart berdasarkan pageviews per pengguna.
- e. Distribusi Durasi Sesi
- Distribusi durasi sesi pengguna ditampilkan dalam histogram dengan garis rata-rata.
- f. Heatmap Pengguna Baru
- Heatmap menunjukkan halaman yang paling banyak dikunjungi oleh pengguna baru.

### 3 2. Actionable Insight:

- a. Peningkatan Pengalaman Pengguna Baru
- Mengidentifikasi halaman yang paling banyak dikunjungi oleh pengguna baru dapat membantu fokus pada peningkatan pengalaman pengguna baru.
- Menganalisis jenis konten yang paling banyak dilihat oleh pengguna dan sumber/medium trafik yang efektif dapat memberikan wawasan untuk strategi pemasaran.
- b. Optimalisasi Trafik
- Analisis sumber/medium trafik dapat membantu dalam pengoptimalan upaya pemasaran, dengan fokus pada saluran yang paling efektif dalam meningkatkan jumlah pageviews per pengguna.
- c. Peningkatan Interaksi

- Fokus pada halaman yang paling banyak dikunjungi dan memastikan bahwa pengguna memiliki pengalaman yang memuaskan di halaman-halaman tersebut dapat meningkatkan interaksi dan retensi.
- d. Pengelolaan Durasi Sesi
- Distribusi durasi sesi memberikan gambaran tentang seberapa lama pengguna tetap di situs. Jika distribusi cenderung singkat, mungkin perlu diidentifikasi area yang dapat ditingkatkan untuk mempertahankan pengguna lebih lama.

### 4 Kesimpulan Akhir:

Analisis data ini memberikan wawasan tentang perilaku pengguna, efektivitas sumber/medium trafik, dan kinerja halaman. Tindakan yang diambil berdasarkan temuan ini dapat membantu meningkatkan pengalaman pengguna, mengoptimalkan sumber trafik, dan meningkatkan interaksi di situs web.